

引用格式: 石威, 李昕泽, 黄文昌, 等. 基于改进 MultiResUNet 网络的甲状腺超声图像分割[J]. 声学技术, 2022, 41(2): 228-234. [SHI Wei, LI Xinze, HUANG Wenchang, et al. Thyroid ultrasound image segmentation based on an improved MultiResUNet network[J]. Technical Acoustics, 2022, 41(2): 228-234.] DOI: 10.16300/j.cnki.1000-3630.2022.02.012

基于改进 MultiResUNet 网络的甲状腺 超声图像分割

石 威^{1,2}, 李昕泽², 黄文昌^{1,2}, 王宁浩^{1,2}, 焦 阳², 崔峭峭²

(1. 中国科学技术大学生物医学工程学院(苏州) 生命科学与医学部, 安徽合肥 230026;
2. 中国科学院苏州医学工程技术研究所医用声学室, 江苏苏州 215163)

摘要: 甲状腺超声图像分割在临床超声图像研究中有很重要的意义。针对甲状腺超声图像信噪比低, 斑点噪声多, 且甲状腺形态不确定等问题, 提出了一种改进的 MultiResUNet 分割网络(称为 Oct-MRU-Net 网络)。该方法在 MultiResUNet 网络的基本结构的基础上引入 Octave 卷积, 并采用改进的 Inception 模块学习不同空间尺度的特征, 将训练过程中的特征图按通道方向分为高低频特征。其中, 高频特征描述图像细节和边缘信息, 低频特征描述图像整体轮廓信息。在甲状腺超声图像分割过程中可以重点关注高频信息, 减少空间冗余, 从而实现对边缘更加精细的分割。实验结果表明, Oct-MRU-Net 网络的性能相较于 U-Net 网络和 MultiResUNet 网络都有较大的提升, 说明该网络对甲状腺超声图像的分割效果较好。

关键词: 甲状腺; 超声; Octave 卷积; MultiResUNet

中图分类号: R312

文献标志码: A

文章编号: 1000-3630(2022)-02-0228-07

Thyroid ultrasound image segmentation based on an improved MultiResUNet network

SHI Wei^{1,2}, LI Xinze², HUANG Wenchang^{1,2}, WANG Ninghao^{1,2}, JIAO Yang², CUI Xiaoyao²

(1. School of Biomedical Engineering (Suzhou), Division of Life Sciences and Medicine, University of Science and Technology of China, Hefei 230026, Anhui, China; 2. Medical Acoustic Department, Suzhou Institute of Biomedical Engineering and Technology Chinese Academy of Sciences 215163, Suzhou, Jiangsu, China)

Abstract: The ultrasound image segmentation of thyroid is very important in clinical ultrasonography. In view of the problems of the low signal-to-noise ratio, high speckle noise and uncertain thyroid morphology in thyroid ultrasound images, an improved MultiResUNet segmentation network, named as Oct-MRU-Net, is proposed by combining the basic structure of MultiResUNet network and Octave convolution. And, the improved Inception module is used to learn the features of different spatial scales. The feature map in the training process is divided into high and low frequency features according to the channel direction, in which the high frequency features describe the image details and edge information and the low frequency features describe the overall image contour information. Then, the method of ultrasound image segmentation can focus on high-frequency information to reduce spatial redundancy, so more precise edge segmentation can be achieved. The experimental results show that the performance of Oct-MRU-Net network is better than that of U-Net network and MultiResUNet network, and so the Oct-MRU-Net network has better segmentation effect on thyroid ultrasound images.

Key words: thyroid; ultrasound; Octave convolution; MultiResUNet

0 引 言

甲状腺是人体重要的器官, 其大小形态的变化在临床医学的诊断中有很重要的意义。目前, 临床

上常用超声来检查甲状腺^[1-3], 但是由于甲状腺周围结构复杂, 且甲状腺的形状和大小具有多样性^[4], 导致对甲状腺的分割比较困难。

随着医学影像技术的发展, 临床检查普及了计算机辅助诊断手段, 促进了医学图像分割技术的发展, Long 等^[5]提出了全卷积神经网络(Fully Convolutional Network, FCN), 该网络将图像级的分类网络应用到图像分割领域, 实现了像素级分类; Ronneberger 等^[6]基于 FCN 分割结果较粗糙的缺点,

收稿日期: 2021-02-01; 修回日期: 2021-03-16

基金项目: 国家自然科学基金(51805529)资助项目。

作者简介: 石威(1996—), 男, 山西临汾人, 硕士研究生, 研究方向为超声图像处理。

通信作者: 崔峭峭, E-mail: cuiyy@sibet.ac.cn

提出了 U-Net, 该网络采用了对称式的编码-解码结构, 并采用跳跃连接将编码阶段与解码阶段的特征相融合, 从而实现了更精确的分割; Ding 等^[7]提出了一种改进的 U-Net 模型(ReAgU-Net), 该网络模型将改进后的残差单元嵌入编码和解码路径之间的跳跃连接中, 并引入注意力机制将浅层和深层获得的权值特征映射加倍; Ibtehaz 等^[8]提出了 MultiResUnet 网络, 将原有的卷积层替换成改进的 Inception 块, 能比较好解决图像不同尺度的问题, 并引入 Res Path 模块, 减小了编码器与解码器对应阶段之间可能存在的语义鸿沟; Chen 等^[9]提出一种即插即用的新型卷积 Octave 卷积, 将特征图分为高低频通道, 减少空间冗余, 且该卷积可以在不改变网络结构的前提下替换传统卷积; 沈雪雯等^[10]提出了一种基于 U-Net++ 的空间分频超声图像分割注意力网络(SFDA-Net), 该网络引入了 Octave 卷积、CBAM 注意力模块等实现超声图像的分割; 唐柳等^[11]在 U-Net 架构的基础上, 结合 Octave 卷积, 提出了一种用于超声心动图的分割网络。

由于超声图像存在大量的固有缺陷, 如斑噪声严重、对比度低、伪影等, 自动准确分割超声图像非常困难。这些缺陷综合起来, 使得分割效果不理想^[12-14]。本研究针对甲状腺超声图像的特性, 以 MultiResUNet 网络为基线, 利用其 MultiRes 模块实现对不同大小和形态的甲状腺的分割, 并结合 Octave 卷积, 将训练过程的特征图按通道分为高频和低频部分。高频部分描述了灰度剧烈变化的边缘和细节信息, 低频部分描述了灰度平稳变化的轮廓信息^[15], 对两部分设置不同的权重, 重点关注高频的边缘和细节信息, 可有效地从信噪比较低的超声图像中分割出甲状腺, 且对于边缘的分割更加

精细。

1 方法

1.1 MultiResUNet 网络

MultiResUNet 网络是基于 U-Net 提出的一种新型的网络结构^[8], 与 U-Net 网络结构相似, 网络分为编码和解码两部分, 如图 1 所示。该网络在 U-Net 的基础上引入多残差(MultiRes)模块和残差路径(Res Path)模块。MultiRes 模块的结构如图 2 所示, 该模块借鉴了 Inception 网络的思想, 分别使用 3×3 、 5×5 、 7×7 不同尺寸的卷积核来提取特征, 并将输出结果按通道方向拼接, 以学习不同尺寸的空间特征, 该模块使用 2 个 3×3 的卷积层来代替 5×5 的卷积层, 使用 3 个 3×3 的卷积层代替 7×7 的卷积层, 减少了网络参数量且可以加速网络训练, 同时, 引入了使用 1×1 卷积的残差结构。使用该模块替换了 U-Net 的卷积层。

Res Path 模块结构如图 3 所示, 没有直接将编码器的特征图与解码器特征图简单拼接在一起, 而是通过一系列卷积层传递编码器特征。这些额外的非线性操作可以减少编码器和解码器特征之间的语义差距。此外, 还引入了使训练更容易、并且在深度卷积网络中非常有用的残差连接。

1.2 Octave 卷积方法

Octave 卷积借鉴了自然图像中高频信息描述图像的细节特征、低频信息描述图像的轮廓特征的思想。该方法指出对于普通卷积, 所有输入和输出特征图具有相同的分辨率是没有必要的, 因为一些特征图表示低频信息, 存在空间冗余, 可以进一步压缩。为了减少空间冗余, 将特征图按通道方向分




图 1 MultiResUNet 网络结构
Fig.1 The architecture of MultiResUNet network




图2 MultiRes 模块结构
Fig.2 The structure of MultiRes module




图3 Res Path 模块结构
Fig.3 The structure of Res Path module

为高频 X_H 和低频 X_L 两个组, 并且将低频特征图的空间分辨率降低为高频特征图的一半^[9]。Octave 卷积层如图 4 所示。




图4 Octave 卷积模块结构
Fig.4 The structure of Octave Convolution module

图 4 中, C 表示通道数, h 、 w 表示特征图的尺寸, $\alpha \in [0, 1]$ 表示高低频信息的比例, 所以, 最终的输出可表示为

$$Y = Y^H + Y^L \quad (1)$$

Y^H 和 Y^L 的表达式为

$$Y^H = f(X^H; W^{H \rightarrow H}) + \text{upsample}[f(X^L; W^{L \rightarrow H}), 2] \quad (2)$$

$$Y^L = f(X^L; W^{L \rightarrow L}) + f[\text{pool}(X^H, 2); W^{H \rightarrow L}] \quad (3)$$

其中: $\text{upsample}(X, n)$ 表示系数为 n 的上采样操作, $\text{pool}(X, n)$ 表示参数为 n 的池化操作, $f(X, W)$ 表示卷积核为 W 的卷积操作。

Octave 卷积被设计为即插即用, 无需调整网络结构, 也不用调整参数, 即可用在常用的卷积神经网络中, 该方法在第一层 Octave 卷积中设置 $\alpha^{\text{in}}=0$ 、 $\alpha^{\text{out}}=1$, 实现将输入的特征转化为多频特征表示, 在最后一层 Octave 卷积中设置 $\alpha^{\text{in}}=1$ 、 $\alpha^{\text{out}}=0$, 实现最终的单个频率特征的输出。在其他特征层, 设置 $\alpha^{\text{in}}=\alpha^{\text{out}}=\alpha$ 。

1.3 Oct-MRU-Net 网络

由于甲状腺超声图像形态不确定, 且信噪比低, 斑点噪声较多, 导致使用常规的分割算法无法准确分割出甲状腺。MultiResUNet 网络针对形态不确定的问题有了较好的解决方案, 但是无法解决图像噪声等问题。本研究将 MultiResUNet 网络与 Octave 卷积相结合, 提出了改进的 MultiResUNet 网络(简称 Oct-MRU-Net)。

Oct-MRU-Net 网络在网络特征提取部分, 将 MultiResNet 网络的传统卷积替换为 Octave 卷积, 有针对性地对图像的高低频特征进行学习, 并降低低频特征的空间冗余, 在能学习不同空间尺度特征的前提下, 可以有效地从信噪比较低的图像中分割出待测目标。Oct-MRU-Net 网络的结构如图 5 所示。




图5 Oct-MRU-Net 网络结构
Fig.5 The architecture of Oct-MRU-Net network

Oct-MRU-Net 网络保留 U-Net 网络的基本结构, 对输入图像做平均池化, 将其分辨率降低为原图的一半, 并将其和原图同时作为 Octave MultiRes 模块的输入。在下采样阶段, 使用了 4 个 Octave MultiRes 模块进行特征提取, Octave MultiRes 模块的结构如图 6 所示。对每个 Octave MultiRes 模块得到的特征进行 Relu 激活以及批归一化操作。在上采样阶段, 使用转置卷积增大特征图的分辨率, 然后再经过 Octave MultiRes 模块进行特征提取, 并通过 Octave Res Path 模块将下采样阶段与上采样阶段的特征进行融合, Octave Res Path 模块如图 7 所示。编码器特征和解码器特征映射之间的语义差距可能会随着网络加深而减小, 所以在 Octave Res Path1、2、3、4 中逐渐减少了 Octave 卷积模块的数量, 分别使用了 4、3、2、1 个 Octave 卷积模块。




图 6 Octave MultiRes 模块结构

Fig.6 The structure of Octave MultiRes module




图 7 Octave Res Path 模块结构

Fig.7 The structure of Octave Res Path module

最后, 将 Octave MultiRes 模块的低频输出进行上采样, 增大其分辨率, 与高频通道的输出相加, 并使用 1×1 卷积融合其通道间的差异, 最终输出同时包含高低频信息的结果。

2 实验与分析

2.1 实验准备

本实验使用的数据集为 Wunderling 等^[16]提供的甲状腺公开数据集, 其中包括以 11~16 MHz 频段超声换能器采集的 16 位健康志愿者的甲状腺图像, 并通过手动标记得到对应的标签。经过数据清洗, 去除一些缺失值, 即没有甲状腺的图像, 保证所有参与训练的数据都是有效的, 最终保留了 1 000 个训练图像和 200 个测试图像作为数据集。

本文的实验在 Windows10 平台下进行, 基于

Tensorflow2.1.0 和 Keras2.3.1 深度学习框架搭建了训练环境。在训练网络时, 选择了二值交叉熵作为损失函数, 选择了 Adam 作为优化器, 初始学习率设置为 1×10^{-4} 。

本文采用图像的平均交并比(Mean Intersection over Union, mIoU), Dice 系数(Dice coefficient)以及灵敏度(Sensitivity, SE)作为算法评价指标。评价指标如式(4)~(6)所示:

$$m_{IoU} = \frac{1}{c} \sum_i \frac{P_{Ti}}{P_{Ti} + N_{Fi} + P_{Fi}} \quad (4)$$

$$C_{Dice} = \frac{2P_T}{2P_T + P_F + N_F} \quad (5)$$

$$S_E = \frac{P_T}{P_T + N_F} \quad (6)$$

式中: c 表示类别数(前景或者背景), P_T 表示正确分类的正样本数, 即预测为正样本, 实际也是正样本; P_F 被错误地标记为正样本的负样本数, 即实际为负样本而被预测为正样本; N_F 指被错误地标记为负样本的正样本数, 即实际为正样本而被预测为负样本。

2.2 实验及结果

分别使用 U-Net 网络、MultiResUNet 网络与 Oct-MRU-Net 网络针对甲状腺数据集进行训练及测试。 α 越大, 低频通道所占比例就越大, 网络参数量会相应地变小。为了研究不同的 α 值对网络性能的影响, 本实验选择了 3 个 α 进行测试, 测试结果如表 1 所示。

表 1 不同参数 α 的网络性能
Table 1 The performances of the networks with different parameters α

α	参数量	可训练参数量	mIoU
0.25	7 189 451	7 165 395	0.911
0.50	7 087 911	7 063 855	0.902
0.75	7 084 720	7 060 664	0.895

由表 1 可以看出, 当 $\alpha=0.25$ 时, $m_{IoU}=0.911$, 当 $\alpha=0.75$ 时, $m_{IoU}=0.895$, α 从 0.75 变为 0.25 时, 模型参数量仅增加了 104 731, 但性能有较大的提升。 α 越小, 网络模型参数量越大, 网络性能相对越好, 但是如果 $\alpha=0$ 时, 此时全部是高频通道, 网络无法学习低频特征, 失去了 Octave 卷积的意义。所以本实验选择 $\alpha=0.25$ 探究网络的性能。

训练过程中的 mIoU 如图 8 所示, 可以看出, Oct-MRU-Net 网络在第 35 次左右收敛, mIoU 最终收敛在为 0.91, MultiResUNet 网络在第 45 次左

右收敛, mIoU 最终收敛在为 0.89, U-Net 网络在第 65 次左右收敛, mIoU 最终收敛在为 0.87, 所以 Oct-MRU-Net 网络收敛后的 mIoU 相较于 U-Net 网络和 MultiResUNet 网络都有明显的提升, 且 Oct-MRU-Net 网络收敛速度较快。

测试结果如图 9、10 所示, 其中, 图 9(a)、10(a) 表示原始图像, 图 9(b)、10(b) 表示标签图像(Ground Truth), 图 9(c)、10(c) 表示使用 U-Net 网络分割结果, 图 9(d)、10(d) 表示使用 MultiResUNet 网络分割的结果, 图 9(e)、10(e) 表示使用本文方法(Oct-MRU-Net 网络)分割的结果。从图 9 中可以看出, 相较于




图 8 训练过程中三个不同网络的平均交并比(mIoU)
Fig.8 The mIoUs of three different networks in training process




图 9 三种不同算法的结果对比(1)
Fig.9 Comparison of three different algorithms (1)




图 10 三种不同算法的结果对比(2)
Fig.10 Comparison of three different algorithms (2)

MultiResUNet 网络和 U-Net 网络, Oct-MRU-Net 网络由于使用高低频的思想, 对高频细节信息更加敏感, 分割的边缘比较精细, 如图中蓝色框标注处所示。从图 10 中可以看出, U-Net 网络对小目标无法实现有效分割, 而 Oct-MRU-Net 网络和 MultiResUNet 网络由于使用了多尺度特征提取的思想, 对小目标表现更加友好, 相对 MultiResUNet 网络, 由于 Oct-MRU-Net 网络较多地关注高频细节信息, 对小目标分割效果更好。

测试集在三个模型上针对上述指标进行了分析, 并且结合了冉冬梅等^[14]提出的针对甲状腺超声图像分割的传统算法进行对比, 结果如表 2 所示。从表 2 中可以看出, 在参数量相差不大的情况下, Oct-MRU-Net 网络模型性能较好, 在各个评价指标上都有提升, 相比 MultiResUNet 网络, Oct-MRU-Net 网络在 mIoU 提高了 0.017 左右, Dice 系数提高了 0.013 左右, 在 SE 指标上提高了 0.021 左右。说明本文算法对于甲状腺超声图像分割有较好的效果。

表 2 三种算法性能比较的结果
Table 2 The performance comparison results of the three algorithms

网络结构	参数量	mIoU	Dice	SE
U-Net	782 000 0	0.874	0.952	0.942
MultiResUNet	723 000 0	0.894	0.961	0.954
Oct-MRU-Net	718 000 0	0.911	0.974	0.975

3 结论

本文提出了一种基于 Oct-MRU-Net 网络的甲状腺超声图像分割算法。该算法通过引入 MultiRes 模块, 更好地学习了不同的空间特征; 通过引入 Res Path 模块, 减少编码器和解码器特征之间的语义差距; 通过引入 Octave 卷积的分频机制, 对高频细节更加敏感, 分割的边缘更加精细。实验结果表明, 本文算法在相同的硬件环境及相同量级的参数量下, mIoU, Dice 系数, SE 等指标都有明显的提升。这说明该算法对甲状腺超声图像有较好的分割效果。从分割结果可知, 本文算法具有检测小目标的能力, 且对边缘和细节的分割效果更加精细。

本文中的算法对甲状腺超声图像具有通用性, 可针对甲状腺不同的疾病进行检测, 且有较高的准确率和鲁棒性。但由于 Octave 卷积中的参数 α 需要人为设定, 缺乏自适应性, 一定程度上影响了甲状腺超声图像的分割效率。因此, 在今后的研究中, 将考虑如何自适应设置参数 α , 提高甲状腺分

割效率。

参 考 文 献

- [1] CHEN J Y, YOU H J, LI K. A review of thyroid gland segmentation and thyroid nodule segmentation methods for medical ultrasound images[J]. Computer Methods and Programs in Biomedicine, 2020, **185**: 105329.
- [2] MA J L, WU F, JIANG T A, et al. Ultrasound image-based thyroid nodule automatic segmentation using convolutional neural networks[J]. International Journal of Computer Assisted Radiology and Surgery, 2017, **12**(11): 1895-1910.
- [3] ZHOU S J, WU H, GONG J, et al. Mark-guided segmentation of ultrasonic thyroid nodules using deep learning[C]//ISICDM 2018: Proceedings of the 2nd International Symposium on Image Computing and Digital Medicine. 2018: 21-26.
- [4] 胡屹杉, 秦品乐, 曾建潮, 等. 基于特征融合和动态多尺度空洞卷积的超声甲状腺分割网络[J]. 计算机应用, 2021, **41**(3): 891-897.
HU Yishan, QIN Pinle, ZENG Jianchao, et al. Ultrasound thyroid segmentation network based on feature fusion and dynamic multi-scale dilated convolution[J]. Journal of Computer Applications, 2021, **41**(3): 891-897.
- [5] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition. Boston, MA, USA. IEEE, 2015: 3431-3440.
- [6] RONNEBERGER O, FISCHER P, BROX T. U-net: convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015, 2015: 234-241.
- [7] DING J R, HUANG Z C, SHI M D, et al. Automatic thyroid ultrasound image segmentation based on U-shaped network[C]//2019 12th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI). Suzhou, China. IEEE, 2019: 1-5.
- [8] IBTEHAZ N, RAHMAN M S. MultiResUNet: Rethinking the U-Net architecture for multimodal biomedical image segmentation[J]. Neural Networks, 2020, **121**: 74-87.
- [9] CHEN Y P, FAN H Q, XU B, et al. Drop an octave: reducing spatial redundancy in convolutional neural networks with octave convolution[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South). IEEE, 2019: 3434-3443.
- [10] 沈雪雯, 王晓东, 姚宇. 基于空间分频的超声图像分割注意力网络[J]. 计算机应用, 2021, **41**(6): 1828-1835.
SHEN Xuewen, WANG Xiaodong, YAO Yu. Spatial frequency divided attention network for ultrasound image segmentation[J]. Journal of Computer Applications, 2021, **41**(6): 1828-1835.
- [11] 唐柳, 王晓东, 陈哲彬, 等. 基于 Octave 卷积的超声心动图左心室分割方法[J]. 计算机应用, 2020, **40**(S1): 215-219.
TANG Liu, WANG Xiaodong, CHEN Zhebin, et al. Segmentation method of left ventricular echocardiography based on Octave convolution[J]. Journal of Computer Applications, 2020, **40**(S1): 215-219.
- [12] CHEN J Y, LI F, FU Y X, et al. A study of image segmentation algorithms combined with different image preprocessing methods for thyroid ultrasound images[C]//2017 IEEE International Conference on Imaging Systems and Techniques. Beijing, China. IEEE, 2017: 1-5.

- [13] 张波, 徐景竹, 吴琼. 2015 年美国甲状腺学会《成人甲状腺结节与分化型甲状腺癌诊治指南》解读: 超声部分[J]. 中国癌症杂志, 2016, **26**(1): 19-24.
ZHANG Bo, XU Jingzhu, WU Qiong. The interpretation of 2015 American Thyroid Association Management Guidelines for Adult Patients with Thyroid Nodules and Differentiated Thyroid Cancer: Ultrasound part[J]. China Oncology, 2016, **26**(1): 19-24.
- [14] 冉冬梅, 严加勇, 崔峭峭, 等. 基于双边滤波-距离正则化水平集演化算法的甲状腺超声图像分割[J]. 生物医学工程研究, 2019, **38**(2): 170-175.
RAN Dongmei, YAN Jiayong, CUI Yaoyao, et al. Ultrasound image segmentation of thyroid gland based on bilateral filters-distance regularized level set evolution algorithm[J]. Journal of Biomedical Engineering Research, 2019, **38**(2): 170-175.
- [15] 杭华飞. 基于图像高频分量的卷积神经网络去噪方法研究[J]. 电子测量技术, 2020, **43**(19): 9-15.
HANG Huafei. Research on convolution neural network denoising method based on high frequency component of image[J]. Electronic Measurement Technology, 2020, **43**(19): 9-15.
- [16] WUNDERLING T, GOLLA B, POUDEL P, et al. Comparison of thyroid segmentation techniques for 3D ultrasound[C]//SPIE Proceedings, "Medical Imaging 2017: Image Processing. Orlando, Florida, USA. SPIE, 2017: 1013317.