

MA_MultiResUnet: 一种基于改进 MultiResUnet 的 CT 影像肺结节分割方法

卢伟 帅仁俊* 赵宸

(南京工业大学计算机科学与技术学院 江苏 南京 211816)

摘要 肺癌在形成肿瘤之前,往往会以肺结节的形态出现,因此及时对肺结节做出正确诊断对提高患者的生存率有重大的意义。提出一种基于 MA_MultiResUnet 的 CT(Computed Tomography)影像肺结节分割方法来辅助医生诊断肺结节,该方法通过重新定义模型中跳跃连接结构来进一步获得具有多尺度空间信息且重要通道特征突出的特征图以及在解码器中引入通道注意力模块来进行特征校准,从而改善网络对肺结节的分割表现。数据集采用 LIDC-IDRI 公开数据集,将该方法在预处理后的数据集上进行评估,实验结果表明,MA_MultiResUnet 的 Recall、Dice、MIoU 表现分别达到 85.76%、84.24%、86.99%,较已有方法有显著的提升。

关键词 MA_MultiResUnet CT 影像 肺结节 分割 跳跃连接 注意力 特征校准

中图分类号 TP391.41 R734.2 **文献标志码** A **DOI**:10.3969/j.issn.1000-386x.2025.04.034

MA_MULTIRESUNET: A SEGMENTATION METHOD OF PULMONARY NODULES IN CT IMAGES BASED ON IMPROVED MULTIRESUNET

Lu Wei Shuai Renjun* Zhao Chen

(College of Computer Science and Technology, Nanjing Tech University, Nanjing 211816, Jiangsu, China)

Abstract Before lung cancer forms a tumor, it often appears in the form of lung nodules. Therefore, a correct diagnosis of lung nodules in time is of great significance to improve the survival rate of patients. This paper proposes a segmentation method of pulmonary nodules in CT images based on MA_MultiResUnet to assist doctors in diagnosing lung nodules. This method further obtained the feature map with multi-scale spatial information and prominent important channel features by redefining the skip connection structure in the model, and the channel attention module was introduced into the decoder to perform feature calibration, so as to improve the network's segmentation performance of lung nodules. The dataset used the LIDC-IDRI public dataset, and the proposed method was evaluated on the pre-processed dataset. The experimental results show that the Recall, Dice and MIoU performance of MA_MultiResUnet reach 85.76%, 84.24%, 86.99%, respectively, and the segmentation performance is better than the existing ones.

Keywords MA_MultiResUnet CT images Pulmonary nodule Segmentation Skip connection Attention Feature calibration

0 引言

肺癌是一种较为常见的癌症类型,且肺癌是发病率和死亡率增长速度最快、对人群健康和生命威胁最大的恶性肿瘤之一。肺癌在形成肿瘤之前,往往会以肺结节的形态出现,因此对肺结节的诊断十分重要,及

时的诊治可以预防癌症,极大地提高患者的生存率。随着 X 射线电子计算机断层扫描仪(CT)在临床诊治上的普及应用,医生可通过观察患者胸部 CT 影像中肺结节的形态、体积、边缘等特征信息来进行良恶性诊治。但肺结节在 CT 影像中尺寸较小、边缘模糊、易与其他组织混淆,医生用肉眼诊断 CT 中的肺结节较为困难。因此,对 CT 影像中的肺结节进行分割研究具

有重要的价值意义。当前常用的肺结节分割方法主要分为两类:(1)传统的肺结节分割方法;(2)基于深度学习的肺结节图像分割方法。传统的肺结节分割方法主要包括阈值分割法^[1]、形态学法^[2]、聚类法^[3-4]等。传统方法虽然能快速对肺结节实现一定精度的分割,但遇到较为复杂的场景时还是会出现误检等情况,导致欠分割或过分割。而近年来,随着深度学习模型的创新不断发展,应用于图像分割等领域的深度学习技术^[5-6]也逐渐成熟。其中,基于深度学习的肺结节图像分割方法就取得了令人满意的效果。由 Ronneberger 等^[7]提出的 Unet 是在 FCN^[8]的基础上进行改进的一个网络,它主要采用 Encoder-Decoder 结构,Encoder 部分主要负责图像特征提取,Decoder 部分进行特征融合并恢复图像的尺寸。Unet 在图像分割方面表现十分出色;Oktay 等^[9]在 Unet 基础上加入一种 Attention Gate 结构,通过将该结构置于每个跳跃连接的末端来对编码器提供的特征图进行空间校准。Attention Unet 的图像分割性能较好;Zhou 等^[10]创造性地提出 Unet++ 结构,将 1 至 4 层 Unet 通过长连接与短连接全部连在一起,将它们通过特征叠加的方式整合使得网络可以抓取不同层次的特征。Zhou 等还通过在不同 Level 的网络上引入 Deep Supervision 解决了梯度无法反向传播的问题,同时还创造了一个优势——剪枝。将 Unet++ 模型应用于图像分割取得了较好的效果;Ibtehaz 等^[11]提出的 MultiResUnet 模型将 Unet 编码器与解码器各层中 2 个 3×3 的卷积块替换为 3 个连续的 3×3 卷积块,并且将 3 个卷积块的输出拼接在一起,以提取不同尺度的空间特征。同时为了减少编码器-解码器特征融合时特征图之间的特征差距,作者还提出了 Res path 来代替简单的跳跃连接。该模型的分割性能较为鲁棒;Tong 等^[12]提出 Improved Unet 结构,较原始 Unet 加入了残差网络、Batch Normalization 来改进网络模型的最终预测。将 Improved Unet 应用于肺结节分割,效果较原始 Unet 得到显著的提升;Wu 等^[13]在 3D-Unet^[14]基础上提出了一种端到端的多任务和可解释的 3D 卷积神经网络 PN-SAMP 用于肺结节分割,它通过使用多个窗口宽度和窗口中心来丰富结节信息,提高了网络对结节的分割性能,PN-SAMP 对肺结节分割的 Dice 系数较 3D-Unet 提升了约 2%,且 PN-SAMP 的参数量(150 万)仅为 3D-Unet(1 600 万)的十分之一。Cao 等^[15]提出了 DB-ResNet 模型用于肺结节分割,它是一种基于 ResNet^[16]的双分支 CNN 架构。该模型能够同时提取肺结节的多视图和多尺度特征,此外,作者还提出了一

个中心强度池化层用来保留以目标体素为中心的强度特征,从而提升网络对结节的分割性能。DB-ResNet 对小结节和胸膜旁结节的分割性能较为鲁棒。Singadkar 等^[17]提出了一种基于结合长、短跳跃连接的深度反卷积残差网络 DDRN 的肺结节分割方法。作者通过在残差块上继续添加残差连接来提高反卷积网络的性能,这种扩展的残差连接通过结合长跳跃连接与短跳跃连接来交换卷积部分和反卷积部分的信息内容,从而使得整个结构信息可以在网络中平滑地进行传输,此外,卷积部分和反卷积部分的长、短跳跃连接还可以缓解深层次网络进行反向传播时梯度消失的问题,帮助网络进行快速收敛,进而提升网络对肺结节的分割性能。DDRN 对胸膜旁结节的分割性能较为鲁棒。Keetha 等^[18]在 Unet 基础上提出了一种 U-Det 模型用于肺结节分割,该模型通过在编码器和解码器之间采用双向特征网络(Bi-FPN)来整合多尺度特征融合,从而丰富了特征表示,同时还通过实现 Mish 激活函数和掩膜的类权重来提高网络对结节的分割性能。U-Det 对小结节的分割性能较为鲁棒。

1 方法介绍

1.1 MA_MultiResUnet 结构

本文提出一种基于 MA_MultiResUnet 的 CT 影像肺结节分割方法,MA_MultiResUnet 模型如图 1 所示,该模型主要创新部分如下:(1)模型以 MultiResUnet 为主干,同时受到 PSA 整体结构^[19]、SPC 模块^[19]和 CA₁₋₄模块^[20]、CBAM^[21]启发,本文重新定义了跳跃连接结构,在 PSA 结构基础上提出 Msi_path 结构来应用于跳跃连接上,从而获得具有多尺度空间信息且重要通道特征突出的特征图,将此特征图与解码器提供的特征图进行特征融合,从而使得特征融合后的特征图能够包含更多对分割结果有益的信息。(2)受到 CA₁₋₄模块^[20]、CBAM^[21]的启发,本文引入 CAM₁₋₄通道注意力模块对编码器与解码器特征融合后的特征图进行校准,使得重点通道特征得到高注意力系数加权,非重点通道特征得到低注意力系数加权。值得注意的是,在 Msi_path 跳跃连接结构和 CAM₁₋₄中都使用到了注意力模块。可以发现本文将大部分注意力模块都应用在跳跃连接结构与解码器结构上,而不是编码器结构,这主要因为编码器部分作为一个特征提取器,主要任务是进行大量的特征提取,若在编码器部分就应用大量的注意力模块可能会导致一些潜在的有效

特征在早期阶段就被抑制^[20],从而使得分割效果不佳。




图1 MA_MultiResUnet 结构

1.2 Msi_path 跳跃连接结构

主要受到 PSA 整体结构^[19]、SPC 模块^[19]和 CA₁₋₄ 模块^[20]、CBAM^[21]的启发,我们重新定义了跳跃连接的结构,在 PSA 结构基础上提出 Msi_path 结构来应用于跳跃连接上,从而获得具有多尺度空间信息且重要通道特征突出的特征图。我们认为在编码器与解码器进行特征融合时,编码器若能进一步提供具有多尺度空间信息且重要通道特征突出的特征图,那么可能会对最后的分割结果越有利,因此我们将 Msi_path 结构输出的特征图与解码器提供的特征图进行特征融合。Msi_path 结构如图 2 所示。在 Msi_path 结构中,我们用 F_{in} 代表编码器提供的输入特征图,在 Msi_path_1、Msi_path_3、Msi_path_4 处,我们首先通过 1×1 卷积将 MultiRes Block 输出的特征图通道数进行升维,从原先的 426、105、51 升维到 428、108、52。之后将升维后的 F_{in} 输入 SPC (Squeeze and Concat) 模块来获得多尺度空间信息特征图,SPC 模块结构如图 3 所示,该模块具体算法流程如下:首先通过并行地采用 4 种不同尺度的卷积核并且压缩特征图的通道数来提取输入特征图 F_{in} 中多尺度空间信息,从而输出 4 个压缩特征图 ($C_0 - C_3$),然后将 4 个压缩特征图进行 Concat 拼接,形成一个具有多尺度空间特征信息的输出特征图 O_{ut_spc} 。这里我们使用 $(3 \times 3, 5 \times 5, 7 \times 7, 9 \times 9)$ 作为 4 种卷积核的尺寸,并且我们将每种尺度的卷积核个数设置为 $\lfloor C/4 \rfloor$,从而控制每个压缩特征图输出通道为 $\lfloor C/4 \rfloor$ 。同时我们将卷积运算中的 groups 设置为 $\lfloor C/4 \rfloor$ 。整个 SPC 模块的输出可由式(1)和式(2)获得。

$$C_i = \text{Conv2D}(C//4, S_i \times S_i)(F_{in}) \quad (1)$$

$$O_{ut_spc} = \text{Concat}(C_0, C_1, C_2, C_3) \quad (2)$$

式中: $i = (0, 1, 2, 3)$, $C//4$ 表示卷积核的个数, S_i 表示各卷积核的尺寸, $S_i = (3, 5, 7, 9)$, C_i 表示不同尺度的卷积核提取到的压缩特征图, O_{ut_spc} 为各压缩特征图拼

接后的输出。之后为了突出 O_{ut_spc} 中重点通道特征信息,我们使用 CA 模块来获取通道注意力系数,CA 模块结构如图 4 所示,具体算法流程如下:首先将 O_{ut_spc} 中各尺度压缩特征图 $C_0 - C_3$ 分别输入 CA 模块,在 CA 模块中首先分别使用全局最大池化和全局平均池化来提取输入特征图 C_i 中各通道的全局信息,之后分别输出 $C_i^{\max}$ 、 C_i^{avg} ,然后将池化后包含全局信息的特征图 $C_i^{\max}$ 、 C_i^{avg} 输入由两个全连接层(本文中用 1×1 卷积代替)和一个 ReLU 激活函数组成的多层感知机 (Multi-Layer Perception, MLP),从而分别得到 C_i^{ml} 、 C_i^{al} ,再将两者进行 Add 操作,然后使用 Sigmoid 函数激活来获得最后的通道注意力系数 α_i 。将 $C_0 - C_3$ 并行输入 CA 模块来获得各局部尺度特征图上的通道注意力系数 $\alpha_0 - \alpha_3$,之后再对 $\alpha_0 - \alpha_3$ 进行 Concat 拼接得到 α , α 可由式(3) - 式(5)获得。

$$CA(x) = \text{Sigmoid}(MLP(G_{\max}(x)) \oplus MLP(G_{\text{avg}}(x))) \quad (3)$$

$$\alpha_i = CA(C_i) \quad (4)$$

$$\alpha = \text{Concat}(\alpha_0, \alpha_1, \alpha_2, \alpha_3) \quad (5)$$

式中: $i = (0, 1, 2, 3)$, $G_{\max}$ 、 G_{avg} 分别代表全局最大池化、全局平均池化操作, MLP 表示由两个全连接层(本文中用两个 1×1 卷积代替,卷积核个数分别为 $C//2$ 、 C)和一个 ReLU 激活函数组成的多层感知机操作, $\oplus$ 表示元素相加操作, $CA(x)$ 表示将 x 输入 CA 模块后的输出。考虑到 α 只是各局部尺度特征图 $C_0 - C_3$ 上通道注意力系数 $\alpha_0 - \alpha_3$ 的拼接,因此只包含了局部尺度通道注意,而未包含全局尺度通道注意信息,因此还使用 Softmax 对 α 进行重新校准,从而得到了局部尺度和全局尺度结合的通道注意力系数 σ , σ 可由式(6)获得。

$$\sigma = \text{Softmax}(\alpha, a_{\text{xis}} = 1) \quad (6)$$

式中: α 在 Softmax 前需要 reshape 成 $[\text{batch_size}, 4, C//4, 1, 1]$ 形状; a_{xis} 是张量的维度索引。再将 SPC 模块输出的特征图 O_{ut_spc} 与 σ 进行相乘,从而获得经通道注意力加权后的特征图 F_{cal} ,同时为了缓解深层网络在反向传播时发生梯度消失的问题,我们还添加了一条残差连接来融合 O_{ut_spc} 与加权后的特征图 F_{cal} ,从而方便网络进行训练学习。最后得到具有多尺度空间信息且重要通道特征突出的特征图 F_{out} , F_{out} 可由式(7)和式(8)获得:

$$F_{\text{cal}} = \sigma \otimes O_{ut_spc} \quad (7)$$

$$F_{\text{out}} = F_{\text{cal}} \oplus O_{ut_spc} \quad (8)$$

式中: $\otimes$ 表示元素相乘操作,我们将 F_{out} 作为特征融合时编码器提供的特征图。




图2 Msi_path 结构




图3 SPC 模块结构




图4 CA 模块结构

1.3 解码器中通道注意力模块

在特征融合时,解码器提供的是一些高级语义特征图, Msi_path 提供的是多尺度空间信息丰富的低级细节特征图,而这两者对最后的分割结果可能有着不同的影响力,因此对融合后的特征图进行通道特征校准,从而使得重点通道特征信息再次被更高的注意力系数加权。我们引入 CAM_{1-4} 模块对特征融合后的特征图再次进行校准,其结构如图 5 所示,具体算法流程如下:首先将特征融合后的特征图 F_{concat} 输入 CA 模块,在 CA 模块中首先分别使用全局最大池化和全局平均池化来提取输入特征图 F_{concat} 中各通道的全局信息,之后分别输出 F_{max} 、 F_{avg} ,然后将池化后包含全局信息的特征图 F_{max} 、 F_{avg} 输入由两个全连接层(本文中用两个 1×1 卷积代替,卷积核个数分别为 $C//2$ 、 C)和一个 ReLU 激活函数组成的多层感知机(MLP),从而分别得到 δ_{max} 、 δ_{avg} ,再将两者进行 Add 操作,然后使用 Sigmoid 函数激活来获得最后的通道注意力系数 δ 。之后再将 F_{concat} 与通道注意力系数 δ 进行相乘得到注意力加权后的特征图 $F_{weighted}$ 。同时为了缓解深层网络进行反向传播时发生梯度消失的问题从而方便网络进行训练,还使用一个残差连接将 F_{concat} 与 $F_{weighted}$ 进行 Add 操作,从而得到最后的输出结果 F_{res} 。整个过程如式(9) - 式(12)所示。

$CA(x) = \text{Sigmoid}(MLP(G_{max}(x)) \oplus MLP(G_{avg}(x)))$ (9)

$\delta = CA(F_{concat})$ (10)

$F_{weighted} = \delta \otimes F_{concat}$ (11)

$F_{res} = F_{weighted} \oplus F_{concat}$ (12)




图5 CAM_{1-4} 结构

1.4 融入 Msi_path 与 CAM₁₋₄的计算资源消耗

我们列出了分别添加 Msi_path 与 CAM₁₋₄后模型结构以及参数的变化,其结果如表 1、表 2 所示。

表 1 模型结构

结构	编码器	跳跃连接		解码器	
	MRS	Res_path	Msi_path	CAM ₁₋₄	MRS
Baseline	✓	✓			✓
+ CAM ₁₋₄	✓			✓	✓
+ Msi_path	✓		✓		✓
本文	✓		✓	✓	✓

表 2 融入 Msi_path 与 CAM₁₋₄的计算资源消耗

Structure	Params/ × 10 ⁶
Baseline	7.26
+ CAM ₁₋₄	7.01
+ Msi_path	6.22
本文	7.47

表 1、表 2 中 Baseline 是 MultiResUnet, + CAM₁₋₄是在 MultiResUnet 基础上融入 CAM₁₋₄结构, + Msi_path 是在 MultiResUnet 基础上用 Msi_path 代替 Res_path,本文模型是在 MultiResUnet 基础上融入 CAM₁₋₄结构,同时用 Msi_path 代替 Res_path。可以看出同时融入 CAM₁₋₄、Msi_path 结构后,模型参数仅有 7.47 × 10⁶,比 MultiResUnet 仅提升了 0.21 × 10⁶ 左右。

1.5 MA_MultiResUnet 算法流程分析

我们还增加了算法 1 来进一步解释 MA_Multi-ResUnet 网络的流程。设置总训练次数 Epochs 为 20,在每一个 Epoch 中,我们通过设置 BatchSize 来将训练数据分成多个 Step 进行学习,每个 Step 的学习具体流程如下:首先我们将训练集打乱,之后选取 BatchSize 个训练数据输入模型中,先使用编码器中 MultiRes-Block 来提取特征图中的低级细节特征,再使用 Max-Pooling 来缩小特征图尺寸,之后再使用 Msi_path 对编码器提供的特征图再次进行多尺度特征提取,并对重要通道特征信息进行突出。然后在解码器部分恢复图像尺寸、添加 CAM₁₋₄来对特征融合后的特征图进行特征校准和高级语义特征提取。最后我们使用 1 × 1 的卷积操作生成最后的分割结果,激活函数使用 Softmax。之后计算分割结果与真实标签之间的误差,再根据损失函数求得网络中各参数梯度,最后结合学习率进行参数更新。之后再进行下一个 Step 的学习,直到完成一个 Epoch 中所有 Step 的学习,再进行下一个 Epoch 的学习,一直训练到 20 个 Epoch 为止。

算法 1 MA_MultiResUnet

输入:训练数据 Train_set | $i_{mg} = (X_1, X_2, \cdots, X_m), m_{ask} = (Y_1, Y_2, \cdots, Y_m)$

输出:分割结果 $O_{ut_{seg}} | mask = (P_{red_1}, P_{red_2}, \cdots, P_{red_m})$

for 1 to training epochs do

for 1 to k steps do

打乱数据集,并随机选取 $B_{atchSize}$ 个训练数据输入 MA_MultiResUnet

首先在编码器部分使用 MultiResBlock 模块来提取特征:

$Encoder(x) = (MultiResBlock, MaxPooling)(x)$

$O_{ut_{Encoder}} = Encoder(X_{i=1}^{batchsize})$

之后使用 Msi_path 对 $O_{ut_{Encoder}}$ 进行多尺度特征再提取:

$O_{ut_{Msi}} = Msi_path(O_{ut_{Encoder}})$

在解码器部分首先使用反卷积(TransposedConv)来恢复图像尺寸,并将反卷积后得到的特征图与 $O_{ut_{Msi}}$ 进行特征融合,再使用 CAM 对融合后的特征图进行特征校准,再将校准后的特征图输入 MultiResBlock 来继续提取高级特征:

$Decoder(x_1, x_2) = (MultiResBlock, TransposedConv, CAM)(x_1, x_2)$

$O_{ut_{Decoder}} = Decoder(O_{ut_{MRS}}, O_{ut_{Msi}})$

最后使用一个 1 × 1 卷积操作生成最后的分割结果:

$O_{ut_{seg}} = Softmax(Conv2D(2, 1 \times 1)(O_{ut_{Decoder}}))$

计算真实标签与预测标签之间的误差:

$L_{oss} = -\frac{1}{B_{atchSize}} \sum_i Y_i \log P_{red_i} + (1 - P_{red_i} \cdot Y_i) \log(1 - P_{red_i})$

根据损失函数求出梯度并进行网络参数更新:

$\theta_{i+1} = \theta_i - \alpha \Delta$

end for

end for

2 数据集及实验结果分析

2.1 数据集

数据集采用 LIDC-IDRI^[22] 公开数据集,该数据集由胸部医学图像文件(dicom 格式)和对应的诊断结果病变标注(.xml 格式)组成。数据集总共包括 1 018 个研究实例,在这些文件中共有 3 种类别会被标注出:(1) 小于 3 mm 的结节;(2) 大于等于 3 mm 的结节;(3) 大于等于 3 mm 的非结节。我们选取结节作为研究对象,并进行预处理操作,最后得到 11 986 幅图像与 11 986 幅 mask。图 6 展示了预处理后的肺结节图像和相应的 mask。之后我们将数据划分为训练集、验证集、测试集,数据集划分结果如表 3 所示。




图6 预处理后的肺结节图像和 mask

表3 数据集划分结果

数据集划分	LIDC-IDRI		
	训练集	验证集	测试集
数量	7 067	2 447	2 472

2.2 实验细节

2.2.1 训练细节

本文主要在 Python、Tensorflow 环境下进行编程。训练损失函数使用交叉熵损失函数,其计算式如下:

$$L_{oss} = - \frac{1}{N} \sum_i y_i \log y_i^p + (1 - y_i^p) \log(1 - y_i^p) \quad (13)$$

式中: y_i 表示样本*i*的真实标签值, y_i^p 表示样本*i*的预测标签值。优化器选择 Adam, Batchsize 设置为 4, Epoch 设置为 20,初始学习率设置为 10^{-4} ,当验证集上的 Loss 值在连续 5 个 Epoch 内的变化小于 10^{-4} 时,将学习率修改为原来的 0.1 倍,模型参数保存规则是保存验证集上 Dice 指标最高的模型参数。

2.2.2 评价指标

本文评价指标选用 Recall、Dice 和 MIoU。Recall 表示预测值为正且真实值也为正在真实值为正的所有样本中所占的比例,其计算式如下:

$$R_{ecall} = \frac{T_p}{T_p + F_n} \quad (14)$$

式中: T_p 为真正例, F_n 是假反例。

Dice coefficient 是一种集合相似度度量函数,常用于计算两个样本的相似度,其计算式如下:

$$D_{ice} = \frac{2 \times |X \cap Y|}{|X| + |Y|} \quad (15)$$

式中: X 为 Ground Truth, Y 为预测值。

均交并比 (Mean Intersection over Union, MIoU) 是语义分割的一个重要度量指标,其计算的是真实值和预测值两个集合的交并比,计算式如下:

$$M_{IoU} = \frac{1}{k + 1} \sum_{i=0}^k \frac{P_{ii}}{\sum_{j=0}^k P_{ij} + \sum_{j=0}^k P_{ji} - P_{ii}} \quad (16)$$

式中: $k + 1$ 表示类别数 (包含空类), i 表示真实值, j 表示预测值, P_{ij} 表示将*i*预测为*j*。

2.3 实验结果及比较

为验证 Msi_path 与 CAM₁₋₄的有效性,首先使用预处理好的数据集进行消融实验,实验结果如表 4 所示。

表4 消融实验结果 (%)

网络	Recall	Dice	MIoU
Baseline	83.94	83.36	86.22
+ CAM ₁₋₄	84.47	83.66	86.35
+ Msi_path	83.78	83.77	86.56
本文方法	85.76	84.24	86.99

可以看出,分别添加 CAM₁₋₄与 Msi_path 后,模型的 Dice、MIoU 表现都比 Baseline 的表现要好,这证明了 Msi_path 与 CAM₁₋₄的有效性。并且同时添加 Msi_path 与 CAM₁₋₄后,模型的 Recall 达到了 85.76%,Dice 达到了 84.24%,MIoU 达到了 86.99%,相比于 MultiResUnet,性能分别提升了 1.82 百分点、0.88 百分点、0.77 百分点。

之后我们将 Unet、MultiResUnet 模型与本文方法在测试集上进行对比实验,各网络的 Recall、Dice、MIoU 实验表现如表 5 所示。

表5 实验结果 (%)

网络	Recall	Dice	MIoU
Unet	79.66	79.61	84.10
MultiResUnet	83.94	83.36	86.22
+ CAM ₁₋₄	84.47	83.66	86.35
+ Msi_path	83.78	83.77	86.56
本文方法	85.76	84.24	86.99

可以看出,本文方法在所有模型中分割表现最佳,Recall 达到了 85.76%,Dice 系数达到了 84.24%,MIoU 达到了 86.99%。

为了可视化各模型的分割结果,我们使用测试集中 4 幅图片对各网络的分割性能进行可视化测试,测试结果如图 7 所示。




图7 分割结果

可以看出,本文方法在测试集上的可视化分割结果无论在形态、位置、边缘等方面的表现都比其余网络所表现得更加出色。

此外,我们还与其他作者的方法进行比较,对比结果如表 6 所示。

表 6 方法对比结果

方法	数据集	Recall/%	Dice/%	MIoU/%
文献[23]	LIDC-IDRI	—	69.00	—
文献[24]	LIDC-IDRI	—	81.23	—
文献[13]	LIDC-IDRI	—	73.89	—
文献[25]	LIDC-IDRI	87.20	81.00	—
本文	LIDC-IDRI	85.76	84.24	86.99

可以看出,文献[25]在 Recall 指标上表现最佳,但本文方法通过重新定义跳跃连接结构以及使用通道注意力模块来提升模型的分割效率,从而在所有方法中 Dice 系数表现最佳,达到了 84.24%,较其他方法有显著的提升。

3 结 语

本文提出一种基于 MA_MultiResUnet 的 CT 影像肺结节分割方法来辅助医生诊断肺结节,该方法使用的模型通过重新定义跳跃连接结构以及使用通道注意力模块来提高网络对肺结节的分割效率。用具有挑战性的 LIDC-IDRI 数据集对模型的分割性能进行检验,通过大量实验表明,相比一些现有方法,MA_MultiResUnet 模型对肺结节的分割精度最高,Recall、Dice、MIoU 分别达到了 85.76%、84.24%、86.99%。之后继续采集数据集样本来扩充样本量以及进一步改进模型将会是未来的研究工作。

参 考 文 献

[1] Farag A A, Graham J, Elshazly S, et al. Data-Driven lung nodule models for robust nodule detection in chest CT[C]//2010 20th International Conference on Pattern Recognition, 2010.

[2] Kostis W J, Reeves A P, Yankelevitz D F, et al. Three-dimensional segmentation and growth-rate estimation of small pulmonary nodules in helical CT images[J]. IEEE Transactions on Medical Imaging,2003,22(10):1259–1274.

[3] 孙旭辉,田启川,李临生,等. 基于改进的模糊 C 均值聚类的肺结节计算机辅助诊断算法研究[J]. 现代生物医学进展,2010,10(17):3326–3331.

[4] Liu H, Geng F H, Guo Q, et al. A fast weak-supervised

pulmonary nodule segmentation method based on modified self-adaptive FCM algorithm[J]. Soft Computing, 2018, 22(12):3983–3995.

[5] Zhao C, Shuai R, Ma L, et al. Segmentation of dermoscopy images based on deformable 3D convolution and ResU-NeXt++[J]. Medical & Biological Engineering & Computing,2021, 59:1815–1832.

[6] Zhao C, Shuai R, Ma L, et al. Dermoscopy image classification based on StyleGAN and DenseNet201[J]. IEEE Access,2021,9:8659–8679.

[7] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention-MICCAI 2015,2015.

[8] Shelhamer E, Long J, Darrell T. Fully convolutional networks for semantic segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence,2017,39(4):640–651.

[9] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-Net: Learning where to look for the pancreas[EB]. arXiv:1804.03999,2018.

[10] Zhou Z, Siddiquee M M R, Tajbakhsh N,et al. UNet++: A nested U-Net architecture for medical image segmentation[C]//Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support,2018.

[11] Ibtehaz N, Rahman M S. MultiResUNet: Rethinking the U-Net architecture for multimodal biomedical image segmentation[J]. Neural Networks,2020,121:74–87.

[12] Tong G F, Li Y, Chen H R, et al. Improved U-NET network for pulmonary nodules segmentation[J]. Optik,2018, 174:460–469.

[13] Wu B T, Zhou Z, Wang J W, et al. Joint learning for pulmonary nodule segmentation, attributes and malignancy prediction[C]//2018 IEEE 15th International Symposium on Biomedical Imaging,2018.

[14] Çiçek Ö, Abdulkadir A, Lienkamp S S, et al. 3D U-Net: Learning dense volumetric segmentation from sparse annotation[C]//Medical Image Computing and Computer-Assisted Intervention-MICCAI 2016,2016.

[15] Cao H C, Liu H, Song E M, et al. Dual-branch residual network for lung nodule segmentation[J]. Applied Soft Computing,2020,86:105934.

[16] He K M, Zhang X Y, Ren S Q, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR),2016.

[17] Singadkar G, Mahajan A, Thakur M, et al. Deep deconvolutional residual network based automatic lung nodule segmentation[J]. Journal of Digital Imaging, 2020, 33:678–684.

- [18] Keetha N V, Babu P, Annavarapu C. U-Det: A modified U-Net architecture with bidirectional feature network for lung nodule segmentation[EB]. arXiv:2003.09293,2020.
- [19] Zhang H, Zu K, Lu J, et al. EPSANet: An efficient pyramid squeeze attention block on convolutional neural network[EB]. arXiv:2105.14447,2021.
- [20] Gu R, Wang G T, Song T, et al. CA-Net: Comprehensive attention convolutional neural networks for explainable medical image segmentation[J]. IEEE Transactions on Medical Imaging,2021,40(2):699–711.
- [21] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module[EB]. arXiv:1807.06521,2018.
- [22] Han F F, Zhang G P, Wang H F, et al. A texture feature analysis for diagnosis of pulmonary nodules using LIDC-IDRI database[C]//2013 IEEE International Conference on Medical Imaging Physics and Engineering,2013.
- [23] Mukherjee S, Huang X J, Bhagalia R R. Lung nodule segmentation using deep learned prior based graph cut[C]//2017 IEEE 14th International Symposium on Biomedical Imaging (ISBI 2017),2017.
- [24] Jain S, Indora S, Atal D K. Lung nodule segmentation using salp shuffled shepherd optimization algorithm-based generative adversarial network[J]. Computers in Biology and Medicine,2021,137:104811.
- [25] Maqsood M, Yasmin S, Mehmood I, et al. An efficient DA-Net architecture for lung nodule segmentation[J]. Mathematics,2021,9(13):1457.
- [30] Marszaek-Kowalewska K, Zaretskaya A, Souek M. Stanford typed dependencies: Slavic languages application[C]//International Conference on Natural Language Processing,2014:151–163.
- [31] Gao T Y, Yao X C, Chen D Q. SimCSE: Simple contrastive learning of sentence embeddings[EB]. arXiv:2104.08821,2021.
- [32] Cimiano P, Lopez V, Unger C, et al. Multilingual question answering over linked data(QALD-3): Lab overview[C]//International Conference of the Cross-Language Evaluation Forum for European Languages,2013:321–332.

(上接第 216 页)

- [18] Li X R, Lan W Y, Dong J F, et al. Adding Chinese captions to images[C]//ACM on International Conference on Multimedia Retrieval,2016:271–275.
- [19] Wu J H, Zheng H, Zhao B, et al. AI challenger: A large-scale dataset for going deeper in image understanding[EB]. arXiv:1711.06475,2017.
- [20] 刘泽宇,马龙龙,吴健,等.基于多模态神经网络的图像中文摘要生成方法[J].中文信息学报,2017,31(6):162–171.
- [21] 郭淑涛,赵德新.一种基于深度学习的中文图像描述模型[J].天津理工大学学报,2020,36(3):30–35.
- [22] 邓珍荣,张永林,杨睿,等.结合全局和局部特征的 BiG-RU-RA 图像中文描述模型[J].计算机辅助设计与图形学学报,2021,33(1):49–58.
- [23] Zhu S Y, Ng I, Chen Z. Causal discovery with reinforcement learning[EB]. arXiv:1906.04477,2019.
- [24] Chen C, Mu S, Xiao W P, et al. Improving image captioning with conditional generative adversarial nets[C]//33rd AAAI Conference on Artificial Intelligence,2019:8142–8150.
- [25] Papineni K, Roukos S, Ward T, et al. BLEU: A method for automatic evaluation of machine translation[C]//40th Annual meeting of the Association for Computational Linguistics,2002:311–318.
- [26] Lin C Y. ROUGE: A package for automatic evaluation of summaries[C]//42nd Annual Meeting of the Association for Computational Linguistics,2004:74–81.
- [27] Vedantam R, Zitnick C L, Parikh D. CIDEr: Consensus-based image description evaluation[C]//IEEE Conference on Computer Vision and Pattern Recognition,2015:4566–4575.
- [28] Robertson S. Understanding inverse document frequency: On the oretical arguments for IDF[J]. Journal of Documentation,2004,60(5):503–520.

(上接第 200 页)

- [23] Li X P, Wu B, Song J K, et al. Text-instance graph: Exploring the relational semantics for text-based visual question answering[J]. Pattern Recognition,2021,124:108455.
- [24] Wu Y R, Ma Y T, Wan S H. Multi-scale relation reasoning for multi-modal visual question answering[J]. Signal Processing: Image Communication,2021,96:116319.
- [25] YOLOv5[EB/OL]. [2021–10–20]. <https://github.com/ultralytics/yolov5/blob/master/CITATION/cff>.
- [26] Stanovsky G, Dagan I. Open ie as an intermediate structure for semantic tasks[C]//53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing,2015:303–308.
- [27] Du Y, Li C, Guo R, et al. PP-OCRv2: Bag of tricks for ultra lightweight OCR system[EB]. arXiv:2109.03144,2021.
- [28] Ferragina P, Scaiella U. Tagme: On-the-fly annotation of short text fragments[C]//19th ACM International Conference on Information and Knowledge Management,2010:1625–1628.
- [29] Manning C D, Surdeanu M, Bauer J, et al. The Stanford CoreNLP natural language processing toolkit[C]//52nd An-